

1. 로지스틱 함수

로지스틱 회귀모델 → 분류를 위한 범용 함수.

$$f(x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}} : \text{로지스틱 / sigmoid / Squashing func.}$$

$$\rightarrow 0 \leq f(x) \leq 1$$

→ input에 맞추어

$$E(y) = \pi(x=x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$

2. Odds

: 성공 확률 / 실패 확률 $\frac{p}{1-p}$


$$\pi(x=x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}} \rightarrow \text{odds} = \frac{\pi(x=x)}{1 - \pi(x=x)}$$

: 성공 확률 / 실패 확률 대비 1의 성공 확률.


$$\log(\text{odds}) = \beta_0 + \beta_1 x$$

log transform

log
odds



$\Rightarrow \beta_1$: x가 한 단위 증가할 때 log(odds)의 증가분



3. 로지스틱 회귀 모델 파라미터 추정

$$\left[\pi(x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x + \beta_2 x_2 + \dots + \beta_p x_p)}} \right]$$

최대우도 추정법 Maximum Likelihood Est.

$$f_i(y_i) = \pi(x_i)^{y_i} (1 - \pi(x_i))^{1-y_i}$$

$$L = \prod f_i(y_i) \quad \ln(L) = \sum_i y_i \ln \left[\frac{\pi(x_i)}{1 - \pi(x_i)} \right] + \sum_i \ln(1 - \pi(x_i))$$

$$= \sum_i y_i (\beta_0 + \beta_1 x_i + \dots + \beta_p x_{ip}) + \sum_i \ln(1 + e^{\beta_0 + \beta_1 x_i + \dots + \beta_p x_{ip}})$$

$$= \sum_i y_i (\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}) + \sum_i \ln(1 + e^{\beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}})$$

→ $\ln L$: log-likelihood func가 최대화되는 β 결정.

하지만 β 의 최적값이 존재하지 않음.

Cross Entropy = $-\sum p(x) \log q(x)$: 두 분포의 차이
= 음의 log likelihood의 가중평균

log likelihood 최대 = cross entropy 최소.

4. Odds 및 해석

$$\log(\text{odds}) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

: 앞변수 1단위 증가시 $\log(\text{odds})$ 변화량.

Odds Ratio

$$\frac{\text{odds}(x_1+1, x_2, \dots, x_n)}{\text{odds}(x_1, x_2, \dots, x_n)} = e^{\beta_1}$$

: 앞변수 1단위 증가시 변화하는 odds의 비율.

• $\beta > 0 \rightarrow$ 성공률 증가

• $\beta < 0 \rightarrow$ " 감소.

ex) feature 1 - coef $\begin{cases} > 0 : \text{성공률과 양의 상관} \\ < 0 : \text{성공률과 음의 상관} \end{cases}$

- odds ($\beta_1 = 1.058$): 앞변수 1단위 증가하면 뒤변수의 1.058배 증가